

차근차근 데이터 분석과 인공지능 with 파이썬

미션 & 연습문제 정답 (일반용)

류현수, 박진영, 최리사, 최지영, 최미선 공저

 연두에디션

1장. 연습 문제

1번 문제

정답 : ③

해설 : 사람의 언어를 컴퓨터가 이해하도록 만드는 기술은 '자연어 처리'이다. 주어진 전제조건이나 정보를 바탕으로 새로운 결론을 도출하거나 처리하는 기술은 '자동추론' 이라는 기술이고, 사진이나 동영상에서 필요한 정보를 찾기 위해 컴퓨터가 시각 기능을 갖도록 하는 기술은 '컴퓨터 비전'이다.

2번 문제

정답 : ②

해설 : 사람의 신경망을 본 뜬 퍼셉트론이라는 개념은 1950년대에 처음 등장한 개념이다.

3번 문제

정답 : 인간성(Humanity)

해설 : 우리나라는 2020년 12월 국가 인공지능 윤리 기준에서 인공지능이 지향하는 최고의 가치를 인간성으로 정하고 그에 대한 3대 원칙과 10대 핵심 요건을 제시했다.

4번 문제

정답 : 데이터의 양(Volume), 속도(Velocity), 다양성(Variety)

해설 : 빅데이터는 많은 데이터의 양과 빠른 속도, 그리고 형태의 다양성을 그 특징으로 갖는다.

3장. 미션

정답)

```
a = 1
while ( a <= 3 ):
    print('안녕', a)
    a = a + 1
```

해설) while 문은 조건이 만족하는 동안 반복하는 구문이다. 초기값이 1인 변수 a 가 1씩 증가하여 3보다 작거나 같은 동안 반복된다. 그러나 while문에서 a 변수 값이 변화되지 않아 계속 a=1 이기 때문에 무한반복한다. a 값을 1 씩 증가시켜야 한다.

3장. 연습 문제

1번 문제

정답 : ④

해설 : 파이썬 변수명으로 사용 가능한 문자는 영어 알파벳, 숫자, _ (언더바)이다. 그 중에서 변수의 첫 글자는 반드시 영어 알파벳과 _(언더바) 로 시작해야 한다.

2번 문제

정답 : ③

해설 : $7 // 2$ 는 7을 2로 나눈 몫의 정수부 값만 가져오는 연산이다. $30/2$ 는 15.0인 실수 값을 출력한다.

3번 문제

정답 : ③

해설 : `input()` 함수로 입력한 값은 숫자가 아닌 문자열 타입으로 저장된다. 변수 a, b 모두 문자열 타입으로 + 연산을 하게 되면 두 개의 문자열을 붙여준다.

4번 문제

정답 : ①

해설 : 문자열을 출력하기 위해 서식 문자열 `s` 를 사용하고, 자릿수 지정을 위해 `s` 앞에 5을 붙여준다.

5번 문제

정답 : `%4.2f`

해설 : 실수에 대해 서식을 지정하는 문자열은 `%f` 를 사용한다. 출력 결과를 보면 소수점 아래 2자리만 보여주므로 소수점 아래 자릿수는 2로 지정해야 하고, 소수점 포함 총 4자리이므로 `%4.2f`라고 적으면 된다.

6번 문제

정답 : 11

해설 : 1부터 10까지의 수를 가져와 합산하려면 `range()` 함수의 범위값 지정을 1부터 11 이라고 해야 1부터 10까지 반복된다.

7번 문제

정답 : `break`

해설 : 반복문을 강제로 벗어나게 하는 명령문은 `break` 이다. `continue` 는 반복문에서 다음 반복을 계속하도록 지정한다. `pass` 는 아무 것도 하지 않는 명령으로 문법상 문장이 있어야 하지만 프로그램에서 특별히 할 일이 없을 때 사용하는 명령이다.

8번 문제

정답 : `return r`

해설 : 계산 결과를 함수를 호출한 곳으로 넘겨주려면 `return` 명령과 함께 넘겨줄 값을 나란히 적어야 한다.

5장. 연습 문제

1번 문제

정답 : [2, 4, 6, 8, 10, 12]

해설 : 2차원 리스트 `[[1, 2, 3], [4, 5, 6]]` 을 `array()`를 이용하여 2차원 배열로 생성한다. 그 뒤에 생성한 2차원 배열을 `flatten()` 을 사용하여 1차원으로 변환하고, 다시 2를 곱하도록 지정했기 때문에 실행 결과로 생성된 배열은 1차원 배열 형태이면서 배열의 각 항목값은 원래 배열 항목값에 2를 곱한 값을 갖는다.

2번 문제

정답 : ①

해설 : 넘파이 배열은 생성된 뒤에는 항목 개수를 변경할 수 없으며, 한 배열 안의 항목들은 모두 같은 데이터 타입을 갖는다. 그리고, 넘파이 배열은 파이썬 리스트보다 빠른 연산 속도를 가지며, 파이썬 리스트보다 더 적은 메모리를 차지한다.

3번 문제

정답 : 5, 31, 5 혹은 5, 32, 5 혹은 5, 33, 5 혹은 5, 34, 5 혹은 5, 35, 5 가 정답이 될 수 있다.

해설 : 생성한 배열이 5, 10, 15, 20, 25, 30 이므로, 배열 항목의 시작값은 5 이고 31보다 작은 수까지 5만큼 증가하도록 `arange()` 에 인수를 전달해야 한다. 따라서 시작하는 값은 5로 지정하고 증가값은 5로 지정하는데, 배열이 처음 항목은 5, 마지막 항목이 30이 나올 수 있도록 `arange()` 함수의 종료값은 31부터 35까지 지정하면 된다. 35보다 큰 값을 종료값으로 지정하면 배열의 마지막 항목이 35가 된다.

4번 문제

정답 : ③

해설 : `arr1` 의 `shape` 값이 (2,3) 이므로 2행 3열의 배열이라는 것을 알 수 있다. 배열 항목의 타입을 출력하는 `dtype` 값이 `int64` 이므로 2행 3열 형태의 정수 배열을 고르면 보기 ③이 정답이다.

5번 문제

정답 :

```
[4 5 6]
9
[[4 5 6]
 [7 8 9]]
[1 2 3 4 5]
```

해설 : 첫 번째 코드는 1행 전체를 가져오도록 인덱스를 지정한 것이다.

두 번째 코드는 2행 2열의 항목값을 가져오도록 인덱스를 지정한 것이다.

세 번째 코드는 1행부터 2행까지 가져오도록 인덱스의 범위를 슬라이싱한 것이다.

네 번째 코드는 배열 arr1 에서 5 이하인 항목들을 가져오도록 슬라이싱한 것이다.

7장. 미션

◆ 미션1. numpy를 이용하여 생성한 값으로 산점도 그래프 그리기

- ◆ 그래프 그리기 예시 - x축 값은 1부터 10까지 값을 갖도록 `arange()`를 사용하고, y축 값은 1부터 30 사이의 임의의 정수 10개를 갖도록 `randint()`를 사용

❖ 파이썬 코드


```
import numpy as np
import matplotlib.pyplot as plt

x=np.arange(1,11)
y=np.random.randint(1,30,10)

print('x:',x)
print('y:',y)
plt.scatter(x,y,c='r',marker='s')
plt.show()
```

❖ 실행 결과

```
x: [ 1  2  3  4  5  6  7  8  9 10]
y: [ 7  2 17 19 17  2 18  2 11 13]
```



◆ 미션2. 학생별 국어 점수와 수학 점수를 선 그래프로 그리기

1) 코랩을 사용하는 경우

- ◆ 나눔 글꼴 설치

```
!sudo apt-get install -y fonts-nanum
!sudo fc-cache -fv
!rm ~/.cache/matplotlib -rf
```

- ◆ 그래프 그리기

- ❖ 파이썬 코드

```
import matplotlib.pyplot as plt
import pandas as pd

plt.rc('font', family='NanumGothic')
df=pd.read_excel('data1.xlsx')

plt.plot(df['name'], df['kor'], 'g--', marker='o', label='국어점수')
plt.plot(df['name'], df['math'], 'r-', marker='*', label='수학점수')
plt.title('성적 그래프')
plt.xlabel('이름')
plt.ylabel('점수')
plt.legend()
plt.show()
```

2) 주피터 노트북을 사용하는 경우

- ◆ 그래프 그리기


- ❖ 파이썬 코드 : 폰트를 굴림으로 지정하는 경우

```
import matplotlib.pyplot as plt
import pandas as pd

plt.rc('font', family='Gulim')
df=pd.read_excel('data1.xlsx')

plt.plot(df['name'], df['kor'], 'g--', marker='o', label='국어점수')
plt.plot(df['name'], df['math'], 'r-', marker='*', label='수학점수')
plt.title('성적 그래프')
plt.xlabel('이름')
plt.ylabel('점수')
plt.legend()
plt.show()
```

❖ 실행 결과



◆ 미션3. 시본에서 제공하는 penguins 를 이용해서 그래프 그리기


1) load_dataset()을 이용하여 penguins 데이터를 가져온 후 펭귄 품종(species)별 몸무게 (body_mass_g)의 평균을 성별을 구분하여 그래프로 그리기

❖ 파이썬 코드

```
import matplotlib.pyplot as plt
import seaborn as sns

penguins_data = sns.load_dataset('penguins')
sns.barplot(x='species', y='body_mass_g', data=penguins_data, hue='sex')
plt.show()
```

❖ 실행 결과




2) penguins 데이터의 숫자값을 갖는 항목들끼리 상관관계 그래프 그리기

❖ 파이썬 코드

```
sns.pairplot(data=penguins_data)
plt.show()
```

❖ 실행 결과




→ 그래프로 그린 결과 flipper_length_mm 와 body_mass_g가 뚜렷한 상관관계가 있는 것을 알 수 있다.

3) penguins 에서 상관관계가 있는 두 칼럼을 선택하여 산점도와 추세선이 함께 나타나는 그래프 그리기

❖ 파이썬 코드

```
sns.regplot(data=penguins_data, x='body_mass_g',y='flipper_length_mm')
plt.show()
```

❖ 실행 결과



7장. 연습 문제

1번 문제

정답 : ②

해설 : 맷플롯립은 파이썬 기본 패키지에 포함되어 있지 않기 때문에 파이썬 기본 패키지만 사용 중이라면 반드시 `pip install matplotlib` 명령을 사용해서 설치해야 한다.

맷플롯립으로 그래프를 그릴 수 있는 것은 리스트 형태뿐만 아니라 데이터 프레임의 칼럼값을 이용해서 그릴 수도 있다.

맷플롯립으로 그래프를 그릴 때 x축 값으로 범주를 나타내는 문자열도 사용할 수 있다.

2번 문제

정답 : ①

해설 : 제시된 그림은 화면을 가로 1줄, 세로 2칸 즉 1행 2열로 분할해서 두 개의 그래프를 그린 것이다. 따라서 그림처럼 화면을 분할하기 위해서는 `subplots(1, 2)` 라고 지정해야 한다. 그리고 왼쪽부터 순서대로 첫 번째 영역에는 선 그래프, 두 번째 영역에는 막대 그래프가 보이기 때문에 그림처럼 각 영역에 그래프를 그리기 위해서는 `ax[0].plot()`, `ax[1].bar()` 을 사용해야 한다.

3번 문제

정답 : ③

해설 : 범주별 원하는 항목값의 평균을 시본(Seaborn)을 이용해서 막대 그래프로 표현하려면 `barplot()`을 사용해야 한다.

4번 문제

정답 : ②

해설 : 데이터의 분포를 나타내는 산점도와 추세선을 함께 그리려면 시본(seaborn)의 `regplot()`을 이용해야 한다.

9장. 미션

미션) 1단계 : 동반한 형제 자매, 배우자 수에 따른 생존율

정답) `d.groupby('sibsp')['survived'].mean()`

- 2 단계 : 동반한 부모, 자식 수에 따른 생존율

정답) `d.groupby('parch')['survived'].mean()`

- 3 단계 : 단독 승선 여부에 따른 생존율

정답) `d.groupby('alone')['survived'].mean()`

- 4 단계 : 동반 승선 인원수에 따른 생존율 비교를 시각화하여 표현하기

```
f, ax = plt.subplots(1,3,figsize=(10,5))
sns.lineplot(x='sibsp',y='survived', data=d,ax=ax[0])
ax[0].set_title('동반한 형제자매, 배우자 수별 생존율')
ax[0].d['family_size'] = d['sibsp']+d['parch']
ax[0].set_ylabel('생존율')

sns.lineplot(x='parch',y='survived', data=d,ax=ax[1])
ax[1].set_title('동반한 부모, 자식수별 생존율')
ax[1].set_xlabel('동반자 수')
ax[1].set_ylabel('생존율')

sns.barplot(x='alone',y='survived', data=d,ax=ax[2])
ax[2].set_title('단독 승선자의 생존율')
ax[2].set_xlabel('단독 승선 여부')
ax[2].set_ylabel('생존율')

plt.show()
```

- 5 단계 : 형제 자매 배우자와 부모, 자식 수를 모두 합하여 총 동반자 수를 구하여 신규 컬럼 생성

정답) `d['family_size'] = d['sibsp']+d['parch']`

- 6 단계 : 전체 동반자 수(5 단계에서 생성한 family_size)에 따른 생존율을 시각화하여 표현

정답)

```
f, ax = plt.subplots(1,2,figsize=(10,5))
sns.barplot(x='family_size',y='survived',data=d,ax=ax[0])
ax[0].set_title('동반자수별 생존율')
ax[0].set_xlabel('동반자 수')
ax[0].set_ylabel('생존율')

sns.barplot(x='alone',y='survived', data=d,ax=ax[1])
ax[1].set_title('단독 승선자의 생존율')
ax[1].set_xlabel('단독 승선 여부')
ax[1].set_ylabel('생존율')

plt.show()
```

9장. 연습 문제

1번 문제

정답 : ②

해설 : groupby(조회해 보고 싶은 필드명)[그룹화할 필드명].count()를 해야 한다. count()는 개수를 세는 함수이고, mean()은 평균을 구하는 함수이다.

2번 문제

정답 : ①

해설 : seaborn 라이브러리에서 countplot()을 이용해 데이터의 개수를 나타내는 차트를 그릴 수 있다.

3번 문제

정답 : ③

해설 : load_dataset() 을 사용하면 된다.

11장. 미션

앞서 만들었던 의사결정 트리 알고리즘 모델과 K 최근접 이웃 알고리즘 모델을 서로 동일하게 훈련 데이터와 테스트 데이터를 구성하여 랜덤 포레스트 알고리즘 모델을 생성하는 프로그램을 다음의 힌트 코드를 참조하여 완성해 보자. 랜덤 포레스트 알고리즘에 대한 객체를 생성할 때는 의사 결정 트리 알고리즘 모델에 대한 객체를 생성할 때와 달리 `n_estimators` 인수에 의사결정 트리의 개수를 지정해야 한다는 점에 유의해야 한다. 훈련 데이터로 학습을 수행하여 모델을 완성한 후 테스트 데이터로 해당 모델을 평가해 보자. 그리고, 결정 트리의 개수를 변경하여 여러 개의 랜덤 포레스트 알고리즘 모델을 만들어 보면서 정확도가 어떻게 변하는지도 확인해 보자.

힌트 코드 1: `from sklearn.ensemble import RandomForestClassifier`

힌트 코드 2: `RandomForestClassifier(n_estimators=3)`
`# n_estimators : 결정 트리 개수`

정답)

```
import pandas as pd
import numpy as np
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score

df = pd.read_excel('사과배복숭아-학습.xlsx')
df.fillna(0, inplace=True)
df.replace({'fruit': {'사과':0, '배':1, '복숭아':2}}, inplace=True)
x_train = df.iloc[:, 1:]
y_train = df.iloc[:,0]

model_3 = RandomForestClassifier(n_estimators=3,random_state=0)
model_3.fit(x_train, y_train)

model_9 = RandomForestClassifier(n_estimators=9,random_state=0)
model_9.fit(x_train, y_train)

model_15 = RandomForestClassifier(n_estimators=15,random_state=0)
model_15.fit(x_train, y_train)
```

```

df_test = pd.read_excel('사과배복숭아-테스트.xlsx')
df_test.fillna(0, inplace=True)
df_test.replace({'fruit':{'사과':0, '배':1, '복숭아':2}}, inplace=True)
x_test = df_test.iloc[:, 1:]
y_test = df_test.iloc[:, 0]

prd_3 = model_3.predict(x_test)
prd_9 = model_9.predict(x_test)
prd_15 = model_15.predict(x_test)

# 예측값과 테스트 데이터의 정답을 비교해서 정확도 계산
print('정확도(트리 3개) =', accuracy_score(y_test, prd_3))
print('정확도(트리 9개) =', accuracy_score(y_test, prd_9))
print('정확도(트리 15개) =', accuracy_score(y_test, prd_15))

```

```

정확도(트리 3개) = 0.9
정확도(트리 9개) = 0.9
정확도(트리 15개) = 1.0

```

해설) RandomForestClassifier()에서 n_estimators 의 값을 3, 9, 15로 하여 3개 모델을 생성하고 학습한다. 같은 테스트 데이터에 대해 예측을 수행하고, 그 결과와 실제 정답을 비교하여 정확도를 살펴보았다. 트리의 개수에 따라 정확도가 달라질 수도 있다는 것을 확인할 수 있다.

11장. 연습 문제

1번 문제

정답 : ④

해설 : K 최근접 이웃 회귀 알고리즘은 분류가 아닌 회귀 알고리즘으로, 분류에 사용하는 K 최근접 이웃 알고리즘의 동작 방식이 유사하다.

2번 문제

정답 : 0, inplace=True

해설 : fillna() 메소드를 활용하여 결측치 값을 모두 0으로 대체하기 위해 첫 번째 인수를 0으로 하고, 대체된 결과가 df에 반영되도록 inplace=True로 옵션을 지정한다.

3번 문제

정답 : ㉠ → ㉡ → ㉢

해설 : ㉠ 의사결정 트리 알고리즘 머신러닝 수행에 필요한 모듈을 import한 후 ㉡ DecisionTreeClassifier()를 호출하여 의사결정 트리 알고리즘 모델 객체를 생성하고, ㉢ 학습을 수행한다.

4번 문제

정답 : 5

해설 : K가 5일 때 원(●)인 데이터 3개와 사각형(■)인 데이터 2개가 별표(★) 데이터의 이웃이다. 이웃 중 원(●)으로 분류된 데이터가 더 많으므로 별표(★) 데이터를 원(●)으로 분류한다.

5번 문제

정답 : KNeighborsClassifier(n_neighbors=3)

해설 : KNeighborsClassifier()를 호출하여 K 최근접 이웃 알고리즘 모델 객체를 생성하고, n_neighbors를 3으로 하여 이웃의 개수 K를 3으로 설정하였다.

6번 문제

정답 : predict(x_test), accuracy_score(y_test, prd)

해설 : predict() 메소드에 테스트 데이터의 속성값 x_test를 적용하여 결과를 예측한다. 테스트 데이터의 정답이 저장된 y_test와 예측 결과가 저장된 prd를 accuracy_score() 메소드에 전달하여 정확도를 측정한다.

7번 문제

정답 : 재현율

해설 : 재현율은 참인 데이터에 집중하는 평가 방식이다. 수나무를 암나무로 분류할 경우 큰

문제가 되지 않는다. 암나무를 수나무로 잘못 분류할 경우 문제가 발생한다. 진짜 암나무를 암나무로 정확하게 분류해 내는 것이 더 중요하므로 재현율이 더 중요한 평가 지표로 사용되게 된다.

8번 문제

정답 : 정밀도

해설 : 정밀도는 참으로 예측한 데이터에 집중하는 평가 방식이다. 음치를 실력자로 분류했을 경우 문제가 발생한다. 실력자로 예측한 후보자가 진짜 실력자인지가 더 중요하므로 정밀도가 더 중요한 평가 지표로 사용되게 된다.

13장. 연습 문제

1번 문제

정답 : ④

해설 : 비지도 학습은 정답 데이터 없이 학습하는 방식이다.

2번 문제

정답 : ②

해설 : 군집 결과가 최적일 수 있다. 군집 결과에 대한 평가가 이루어져야 한다.

3번 문제

정답 : `n_clusters=5`

해설 : `KMeans()`를 이용해서 군집화 객체를 만들 때 군집의 개수를 지정하는 매개변수는 `n_clusters`이다. 따라서 군집이 5개가 되게 하려면 `n_cluster`에 5를 할당하는 코드를 적어야 한다.

4번 문제

정답 : ③

해설 : 군집 번호를 갖고 있는 속성값은 모델객체.`labels_`에 저장되어 있다.

5번 문제

정답 : ①

해설 : seaborn의 `scatterplot()`을 활용하여 x축의 값으로 `height`, y축의 값으로 `weight`를 사용해야 한다.

6번 문제

정답 : ②

7번 문제

정답 : ①

해설 : ② 평균 실루엣 계수가 1에 가까울수록 군집화가 잘 된 것으로 평가하지만, 0.5 이상이라고 군집화가 잘 이루어졌다고 평가하지는 않는다. ③ 데이터 개수와 실루엣 계수와는 상관관계가 없다. ④ 군집0의 실루엣 계수가 군집1의 실루엣 계수보다 더 높은 값을 갖고 있기 때문에 군집0이 더 잘 군집화 되어 있다고 평가할 수 있다.