

# 3. 꺾의 당도 예측 회귀 모델 만들기

## 데이터 컬럼 설명

Date : 조사 일자

Sour : 꺾의 산도 %

Sweet : 꺾의 당도 Brix

Flesh : 꺾의 과육 비율 %

데이터 출처 : 농업 진흥청 국립원예특작과학원 과수생육품질관리시스템  
(<https://fruit.nihhs.go.kr/> (<https://fruit.nihhs.go.kr/>))

## 데이터 전처리

In [1]:

```
import pandas as pd
import numpy as np

df = pd.read_excel('꺾품질정보.xlsx')
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 105 entries, 0 to 104
Data columns (total 4 columns):
#   Column  Non-Null Count  Dtype
---  -
0   Date    105 non-null      datetime64[ns]
1   Sour    105 non-null      float64
2   Sweet   105 non-null      float64
3   Flesh   105 non-null      float64
dtypes: datetime64[ns](1), float64(3)
memory usage: 3.4 KB
```

In [2]:

```
#날짜 분리
# Datetime 타입인 '날짜' 칼럼에서 연도값을 가져와 'Year'칼럼으로 추가
df['Year']=df['Date'].dt.year
# Datetime 타입인 '날짜' 칼럼에서 월 값을 가져와 'Month'칼럼으로 추가
df['Month']=df['Date'].dt.month
# Datetime 타입인 '날짜' 칼럼에서 일 값을 가져와 'Day'칼럼으로 추가
df['Day']=df['Date'].dt.day
df
```

Out[2]:

|     | Date       | Sour | Sweet | Flesh | Year | Month | Day |
|-----|------------|------|-------|-------|------|-------|-----|
| 0   | 2010-08-05 | 3.41 | 6.54  | 57.70 | 2010 | 8     | 5   |
| 1   | 2010-08-06 | 3.75 | 6.50  | 60.46 | 2010 | 8     | 6   |
| 2   | 2010-08-18 | 3.34 | 6.36  | 68.21 | 2010 | 8     | 18  |
| 3   | 2010-08-31 | 2.92 | 6.17  | 73.65 | 2010 | 8     | 31  |
| 4   | 2010-09-16 | 2.29 | 6.52  | 79.37 | 2010 | 9     | 16  |
| ... | ...        | ...  | ...   | ...   | ...  | ...   | ... |
| 100 | 2021-10-01 | 1.10 | 7.67  | 83.75 | 2021 | 10    | 1   |
| 101 | 2021-10-15 | 0.93 | 8.39  | 83.15 | 2021 | 10    | 15  |
| 102 | 2021-11-01 | 0.90 | 9.16  | 81.93 | 2021 | 11    | 1   |
| 103 | 2021-11-15 | 0.90 | 9.31  | 81.12 | 2021 | 11    | 15  |
| 104 | 2021-11-25 | 0.89 | 9.95  | 80.24 | 2021 | 11    | 25  |

105 rows × 7 columns

In [3]:

```
#상관도 출력
df.corr()
```

Out[3]:

|       | Sour      | Sweet     | Flesh     | Year      | Month     | Day       |
|-------|-----------|-----------|-----------|-----------|-----------|-----------|
| Sour  | 1.000000  | -0.761465 | -0.829606 | -0.148696 | -0.927995 | -0.251077 |
| Sweet | -0.761465 | 1.000000  | 0.526759  | 0.055484  | 0.830212  | 0.192191  |
| Flesh | -0.829606 | 0.526759  | 1.000000  | 0.102154  | 0.681480  | 0.193823  |
| Year  | -0.148696 | 0.055484  | 0.102154  | 1.000000  | 0.127384  | -0.279312 |
| Month | -0.927995 | 0.830212  | 0.681480  | 0.127384  | 1.000000  | 0.085079  |
| Day   | -0.251077 | 0.192191  | 0.193823  | -0.279312 | 0.085079  | 1.000000  |

In [4]:

```
#그래프로 살펴보기
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
sns.regplot(x='Sour', y='Sweet', data=df)
```



```
plt.show()
```


```
sns.regplot(x='Flesh', y='Sweet', data=df)
```

```
plt.show()
```

```
sns.regplot(x='Month', y='Sweet', data=df)
```

```
plt.show()
```





In [5]

#학습 데이터와 테스트 데이터 분리

from sklearn.model\_selection import train\_test\_split

#데이터프레임에서 당도칼럼을 가져와 정답 칼럼(종속변수)을 갖는 변수 y로 저장

y = df['Sweet']

#데이터프레임에서 산도, 월 칼럼을 가져와 속성칼럼(독립변수)을 갖는 변수 x로 저장

x = df[['Sour', 'Flesh', 'Month', 'Day']]

#x = df[['Flesh', 'Month', 'Day']]

#훈련데이터와 테스트 데이터로 분할

x\_train, x\_test, y\_train, y\_test = train\_test\_split(x, y, train\_size=0.8,  
random\_state=0)